

Lab03_Caparrós_ME315A

Enzo Caparrós Carvalho

```
library(dplyr)
library(readr)
```

Hands-On

Exercício 1:

Importe, utilizando o pacote readr, cada um dos três arquivos disponíveis. Os objetos resultantes devem ser chamados flights, airlines e airports.

Para o arquivo de aeroportos, importe apenas as colunas IATA_CODE, CITY, STATE, LATITUDE, LONGITUDE; Para o arquivo de vôos: a. Importe apenas as colunas DESTINATION_AIRPORT e ARRIVAL_DELAY; b. Leia apenas 1 milhão de linhas por vez; c. Remova vôos em que o aeroporto de destino comece com a letra 1; d. Remova registros em que existam pelo menos uma coluna faltante; e. Determine, para cada parte do arquivo, as estatísticas suficientes para a determinação do atraso médio por aeroporto de destino; f. Ao finalizar a leitura do arquivo, combine as estatísticas suficientes de modo a produzir a média de atraso por aeroporto.

```
airlines <- read_csv("airlines.csv")
```

```
airports <- read_csv("airports.csv") |>
  select(IATA_CODE, CITY, STATE, LATITUDE, LONGITUDE)
```

```
getStats <- function(input, pos) {
  input |>
    select(DESTINATION_AIRPORT, ARRIVAL_DELAY) |>
    filter(!grepl("^1", DESTINATION_AIRPORT)) |>
    filter(!is.na(DESTINATION_AIRPORT),
           !is.na(ARRIVAL_DELAY)) |>
    group_by(DESTINATION_AIRPORT) |>
```

```

    summarise(
      n = n(),
      soma_atrasos = sum(ARRIVAL_DELAY),
      .groups = "drop"
    )
  }

```

```

stats <- read_csv_chunked(
  "flights.csv.zip",
  callback = DataFrameCallback$new(getStats),
  chunk_size = 1000000
)

```

```

flights <- stats |>
  group_by(DESTINATION_AIRPORT) |>
  summarise(
    n = sum(n),
    soma_atrasos = sum(soma_atrasos),
    .groups = "drop"
  ) |>
  mutate(
    ARRIVAL_DELAY = soma_atrasos / n
  ) |>
  select(DESTINATION_AIRPORT, ARRIVAL_DELAY)

```

```
head(flights)
```

```

# A tibble: 6 x 2
  DESTINATION_AIRPORT ARRIVAL_DELAY
    <chr>              <dbl>
1 ABE                  5.80
2 ABI                  4.08
3 ABQ                  5.61
4 ABR                 -3.39
5 ABY                  8.68
6 ACK                  4.91

```

Exercício 2:

Selecione a operação apropriada join para incluir, na tabela flights, as colunas CITY e STATE do objeto airports. Para executar esta tarefa:

- Identifique a coluna que é a chave na tabela `flights`;
- Identifique a coluna que é a chave na tabela `airports`;
- Quais são os aeroportos que estão listados em `flights`, mas estão ausentes em `airports`?
- Apresente o comando que combine ambas as tabelas, indicando explicitamente as chaves;
- Armazene a tabela resultante no objeto `flights`.

####a. A chave na tabela `flights` é `DESTINATION_AIRPORT`.

####b.

A chave na tabela `airports` é `IATA_CODE`.

####c.

```
anti_join(
  flights,
  airports,
  by = c("DESTINATION_AIRPORT" = "IATA_CODE")
)
```

A tibble: 0 x 2

i 2 variables: DESTINATION_AIRPORT <chr>, ARRIVAL_DELAY <dbl>

####d. e e.

```
flights <- flights |>
  left_join(
    airports |> select(IATA_CODE, CITY, STATE, LATITUDE, LONGITUDE),
    by = c("DESTINATION_AIRPORT" = "IATA_CODE")
  )
```

Exercício 3:

Quantos aeroportos cada estado possui? Apresente uma tabela ordenada de forma decrescente (no número de aeroportos).

```
airports |>
  count(STATE, sort = TRUE)
```

```
# A tibble: 54 x 2
  STATE      n
  <chr> <int>
1 TX      24
2 CA      22
3 AK      19
4 FL      17
5 MI      15
6 NY      14
7 CO      10
8 MN       8
9 MT       8
10 NC       8
# i 44 more rows
```


Exercício 4:

Apresente um mapa representando todos os atrasos observados por aeroporto.

- Carregue o pacote leaflet;
- Combine os comandos leaflet, addTiles e addMarkers para a criação de um mapa básico;
- Armazene o grafico em b) numa variável chamada this;
- Adicione as duas linhas abaixo após a criação da variável this (apenas se você estiver usando Jupyter):

```
library(leaflet)
```

```
this <- leaflet(flights) |>
  addTiles() |>
  addMarkers(
    lng = ~LONGITUDE,
    lat = ~LATITUDE,
    popup = ~paste(
      "Aeroporto:", DESTINATION_AIRPORT,
      "<br>Cidade:", CITY,
      "<br>Estado:", STATE,
      "<br>Atraso médio:", round(ARRIVAL_DELAY, 2), "minutos"
    )
  )
this
```



```
Sys.setenv(TZ = "America/Sao_Paulo")  
Sys.time()
```

```
[1] "2026-08-31 23:16:57 -03"
```